

ANEXO IV — EVALUACIÓN Y RÚBRICA

Proyecto Integral: Edificios Inteligentes y Sostenibilidad Energética · Curso 2025-2026

La nota del proyecto es **por equipo**. Un equipo puede obtener un 10 y otro un 7. Esa nota se distribuye proporcionalmente entre los módulos del curso según el porcentaje que el profesor determine para cada uno. Los aspectos de **MLOps y calidad** no forman un módulo independiente si ningún equipo resuelve el caso de uso dedicado a ellos. En ese caso, se evaluarán de forma transversal dentro de la evaluación de cada caso de uso donde aplican.

7. Evaluación por módulos del curso

Módulo 1 — Sistemas de Aprendizaje Automático (SAA)

Peso del proyecto en la nota del módulo: **70%**

Aspectos del proyecto que se evaluarán:

- Preparación y preprocesado adecuado de los datos (tratamiento de nulos, normalización, escalado, codificación de variables categóricas), documentado en los notebooks con el razonamiento de cada decisión.
- Reducción de dimensionalidad cuando sea pertinente (PCA, selección de features).
- Aplicación correcta de técnicas de **regresión**: predicción de consumo eléctrico (SARIMA, XGBoost) con validación temporal estricta sin *data leakage*.
- Aplicación de algoritmos de **clasificación**: detección de ocupación (Random Forest, SVM, XGBoost), incluyendo análisis de balance de clases.
- **Aprendizaje no supervisado**: clustering (K-Means, DBSCAN) y detección de anomalías (Isolation Forest, Autoencoder) en sistemas HVAC.
- Evaluación de modelos con **métricas adecuadas al problema**: RMSE, MAE, MAPE para regresión; accuracy, precision, recall, F1-score, AUC-ROC para clasificación; F1 con umbral para detección de anomalías.
- Justificación documentada de la selección de variables y características más relevantes (importancia de features).
- **Registro en MLflow** de todos los experimentos: parámetros, métricas, artefactos. Un experimento no registrado no es evaluable.
- **Baseline obligatorio**: todos los modelos deben compararse con una línea de referencia simple claramente documentada.
- **Versionado en lakeFS** de los datasets de entrenamiento y test: el experimento de MLflow debe referenciar el tag del dataset.

Módulo 2 — Programación en Inteligencia Artificial (PIA)

Peso del proyecto en la nota del módulo: 70%

Aspectos del proyecto que se evaluarán:

- **Dominio de Python** para manipulación de datos, pipelines y entrenamiento de modelos (pandas, NumPy).
- Uso correcto de las librerías del ecosistema ML/DL: scikit-learn, statsmodels, TensorFlow o PyTorch.
- Desarrollo de **redes neuronales para series temporales** (LSTM como mínimo; Transformers como extensión investigada de forma autónoma).
- **Entregables empaquetados y reproducibles**: entorno virtual con requirements.txt o environment.yml que instale todas las dependencias sin intervención manual; docker-compose.yml si aplica.
- **Calidad del código según PEP8** (ver definición en la sección de Entregables): indentación correcta, longitud de líneas, nombres de variables descriptivos, comentarios significativos. Se valorará el uso de black y flake8.
- **Control de versiones** con Git: commits descriptivos, estructura del repositorio clara, .gitignore correcto (los datos y los modelos grandes no deben ir al repositorio).
- **Integración de modelos en interfaces de usuario**: el resultado del modelo debe ser visualizable y comprensible para un usuario no técnico. Herramientas aceptadas: Streamlit, Gradio, React, Flutter o Angular. La elección debe justificarse en función del perfil del equipo y los requisitos de la demo.
- Investigación y documentación de **algoritmos no vistos en clase** (Transformers para series temporales, Codabench): el proceso de aprendizaje e investigación debe estar documentado en los notebooks con referencias a las fuentes consultadas.

Módulo 3 — Modelos de Inteligencia Artificial (MIA) — ampliado con contenidos 2025-26

Peso del proyecto en la nota del módulo: 70%

Aspectos del proyecto que se evaluarán:

Contenidos del Real Decreto 279/2021:

- Descripción y caracterización de la arquitectura de los modelos de IA utilizados en el proyecto (en los notebooks y en la documentación de arquitectura).
- **Procesamiento de lenguaje natural:** comprensión de intenciones del usuario (clasificación de la intención en el router del chatbot), generación de respuestas en lenguaje natural.
- Desarrollo de un **sistema de procesamiento de lenguaje orientado a una tarea específica** (el chatbot meteorológico del Caso H).

Contenidos ampliados 2025-26 (evaluados en este módulo de forma explícita):

- **Sistemas RAG:** diseño e implementación de la arquitectura completa (indexación, recuperación semántica, generación aumentada). El pipeline debe ser funcional y demostrable.
- **ElasticSearch como base de datos vectorial:** indexación de *embeddings*, configuración del índice `dense_vector`, búsqueda por similitud (coseno o producto escalar). Se evaluará la comprensión del proceso de vectorización y recuperación.
- **Agentes de IA:** diseño de agentes con responsabilidades diferenciadas y clara separación de funciones entre ellos.
- **Enrutamiento de agentes:** implementación de un router que clasifica la intención del usuario y dirige la consulta al agente correcto. El enrutamiento debe ser funcional y demostrable con al menos 3 tipos de intención diferentes.
- **Evaluación del LLM:** el equipo del Caso G debe haber evaluado el chatbot con el golden set de preguntas y documentado las métricas de relevancia, coherencia y tasa de alucinación.
- **Uso de LLMs locales con Ollama:** despliegue correcto del servidor, selección justificada del modelo (LLaMA 3, Mistral, Qwen, Gemma 4), y comprensión del impacto de los parámetros de inferencia (temperatura, top-p, context length).

Módulo 4 — Big Data Aplicado (BDA)

Peso del proyecto en la nota del módulo: 30%

Aspectos del proyecto que se evaluarán:

- **Identificación e integración de fuentes de datos** heterogéneas: datasets públicos (BDG2, In-Gauge, UCI, ERA5) + simulación de flujo IoT (Mosquito/Telegraf).
- **Diseño y ejecución de flujos ETL** (Extract, Transform, Load) sobre los datasets del proyecto:
 - Extracción desde el formato original (CSV, ZIP).
 - Transformación: limpieza, normalización, cambio de tipos, renombrado de columnas al esquema de CENTINELA+.
 - Carga en InfluxDB con el esquema de *measurements*, *tags* y *fields* correcto.

- **Definición de esquemas de datos:** documentar los esquemas de cada dataset procesado (nombres de campos, tipos, unidades, descripción) en el repositorio.
- **Dashboards en Grafana:** los dashboards de visualización deben ser funcionales, con paneles relevantes y configuración de alertas donde aplique (CO₂ elevado, anomalía HVAC detectada, consumo por encima del umbral).
- **Documentación del flujo de datos:** diagrama de arquitectura que muestre cómo fluyen los datos desde la fuente original hasta el dashboard, incluyendo los protocolos de comunicación (MQTT, HTTP, Flux) y las transformaciones aplicadas.
- **Calidad de datos en el pipeline:** definición y medición de al menos 3 dimensiones de calidad (completitud, consistencia, validez temporal) sobre los datasets procesados. Documento o notebook de auditoría de calidad.
- **Versionado de datasets en lakeFS:** cada dataset procesado debe estar versionado con un tag etiquetado y un mensaje de commit descriptivo.

Módulo 5 — Sistemas de Big Data (SBD)

Peso del proyecto en la nota del módulo: 30%

Aspectos del proyecto que se evaluarán:

- **Benchmark Spark vs. pandas (Caso I) — evaluado para todos los alumnos aunque no sean del equipo responsable:**
 - Todo el alumnado debe conocer y poder defender el benchmark (qué se midió, qué resultados se obtuvieron, qué conclusiones se extraen).
 - El equipo responsable del Caso I debe poder explicar la arquitectura del clúster, el proceso de configuración y los resultados detallados.
- **Configuración y administración del clúster** (evaluado principalmente para el equipo DevOps/ITI):
 - Instalación y configuración de Hadoop HDFS y Apache Spark en el clúster del ITI.
 - Carga del dataset BDG2 completo en HDFS.
 - **Runbook del clúster:** instrucciones de instalación, configuración, arranque y parada de todos los servicios. Debe ser ejecutable por un administrador externo.
- **Operaciones sobre datos a escala:**
 - Implementación de las 4 operaciones del benchmark en PySpark (filtrado, agregación, join, detección de outliers).
 - Resultados documentados con tiempos de ejecución y consumo de memoria.
 - Comparativa clara y pedagógica: tablas y gráficos que muestren la diferencia entre pandas y Spark.
- **Conclusiones justificadas** sobre cuándo usar Big Data y cuándo no: el límite práctico de pandas, el *overhead* de arranque de Spark, y el punto de cruce donde Spark ofrece ventaja.
- **Kafka (opcional):** demostración de procesamiento de streaming si se ha implementado.

8. Rúbrica de evaluación

8.1 Criterios globales y pesos

Criterio	Descripción breve	Peso
Integración técnica	El sistema funciona de extremo a extremo. Los componentes se comunican correctamente y los flujos de datos son coherentes.	25%
Aplicación de IA y Big Data	Las técnicas son adecuadas al problema. Se justifican las decisiones. Los modelos se comparan con una baseline. Los resultados son medibles.	25%
Calidad de la documentación	El runbook permite reproducir el entorno. Los notebooks están documentados con Markdown. El diagrama de arquitectura es completo.	20%
Vídeo de demostración	Comprensible para público no técnico. Muestra funcionalidad real. Calidad suficiente para portfolio.	15%
Creatividad, iniciativa y escalabilidad	El equipo va más allá del mínimo. La solución está orientada a su reutilización en CENTINELA+. Se proponen mejoras concretas.	10%
Calidad del código (PEP8 y Git)	El código sigue PEP8. El repositorio tiene estructura clara, README actualizado e historial de commits descriptivo.	5%
TOTAL		100%

8.2 Niveles de desempeño

Nivel	Puntuación	Descriptor general
Excelente	9 – 10	El equipo supera los requisitos en la mayoría de criterios. La solución es funcional, bien documentada y claramente orientada a su reutilización en CENTINELA+. El vídeo tiene calidad de portfolio. Los experimentos están en MLflow y los datasets en lakeFS.
Notable	7 – 8,9	El equipo cumple todos los requisitos con solvencia. La solución funciona correctamente. La documentación es suficiente para reproducirla. El vídeo es claro. MLflow y lakeFS están integrados en los flujos principales.
Aprobado	5 – 6,9	El equipo cumple los requisitos mínimos. La solución funciona en sus partes principales, aunque puede haber componentes incompletos. La documentación cubre lo esencial.
Insuficiente	< 5	El equipo no alcanza los requisitos mínimos en uno o más criterios esenciales: la solución no funciona, falta documentación crítica, o el vídeo no existe o no es comprensible.

8.3 Rúbrica detallada por criterio

Criterio 1 — Integración técnica (25%)

Nivel	Descriptor
Excelente (9-10)	Todos los componentes integrados y funcionando de extremo a extremo. Flujo ingesta → InfluxDB → Grafana completamente funcional. Los datos del equipo son consumibles por otros equipos a través de la arquitectura compartida.
Notable (7-8,9)	La mayor parte del sistema está integrada. Pueden existir pequeñas inconsistencias o pasos que requieren intervención manual, pero el flujo principal funciona correctamente.
Aprobado (5-6,9)	El sistema funciona de forma parcial. Al menos el 60% de los componentes planificados están operativos. Los componentes individuales funcionan aunque la integración entre ellos sea incompleta.
Insuficiente (<5)	El sistema no funciona o funciona solo de forma muy limitada. Los componentes están desconectados o presentan errores graves.

Criterio 2 — Aplicación de IA y Big Data (25%)

Nivel	Descriptor
Excelente (9-10)	Las técnicas de IA/Big Data son adecuadas y se justifican. Los modelos se comparan entre sí y con una baseline documentada. El benchmark Spark vs. pandas incluye las 4 operaciones, tiempos medidos y conclusiones pedagógicas. Los experimentos están en MLflow con parámetros, métricas y artefactos. Para el chatbot: el sistema RAG es funcional con al menos 2 agentes y enrutamiento demostrable.
Notable (7-8,9)	Las técnicas son apropiadas. Se presentan métricas de evaluación claras. El benchmark Big Data está realizado aunque puede carecer de análisis en profundidad. MLflow integrado en los flujos principales.
Aprobado (5-6,9)	Se aplican técnicas de IA o Big Data básicas con resultados aceptables. Las métricas de evaluación están presentes pero son limitadas. El benchmark Big Data existe en forma básica. MLflow integrado en al menos un experimento.
Insuficiente (<5)	Las técnicas de IA/Big Data no se aplican de forma real o los resultados no son evaluables. No hay métricas de evaluación o son incorrectas. No hay evidencia de uso de MLflow.

Criterio 3 — Calidad de la documentación (20%)

Nivel	Descriptor
Excelente (9-10)	El runbook permite reproducir el entorno desde cero sin asistencia del equipo. Los notebooks tienen celdas Markdown que explican el razonamiento en cada paso. El diagrama de arquitectura es completo y autodescriptivo. Los experimentos MLflow están referenciados en los notebooks. El documento de distribución de tareas es detallado y justificado.
Notable (7-8,9)	La documentación cubre la mayor parte del sistema. Un técnico externo podría reproducir el entorno con ayuda puntual. Los notebooks tienen

Nivel	Descriptor
	explicaciones en las secciones clave. El documento de distribución de tareas es suficiente.
Aprobado (5-6,9)	Documentación básica pero suficiente. Runbook cubre los pasos principales. Notebooks con mínimas explicaciones.
Insuficiente (<5)	Documentación insuficiente para reproducir el sistema. Faltan runbook, diagrama o documento de distribución de tareas.

Criterio 4 — Vídeo de demostración (15%)

Nivel	Descriptor
Excelente (9-10)	El vídeo es completamente comprensible para público no técnico. Muestra la funcionalidad real en vivo (no capturas estáticas). Conecta de forma clara con CENTINELA+ y el IES Simarro. Tiene calidad técnica y narrativa suficiente para usarse como portfolio. Opcionalmente incluye versión en inglés con voice cloning.
Notable (7-8,9)	El vídeo es comprensible y muestra la funcionalidad principal. Tiene buena calidad técnica y narrativa. La conexión con CENTINELA+ se menciona.
Aprobado (5-6,9)	El vídeo muestra la funcionalidad de forma básica y es comprensible en sus puntos principales, aunque puede carecer de contexto o de calidad técnica suficiente para portfolio.
Insuficiente (<5)	El vídeo no existe, no muestra funcionalidad real, o no es comprensible para el público objetivo.

Criterio 5 — Creatividad, iniciativa y escalabilidad (10%)

Nivel	Descriptor
Excelente (9-10)	El equipo va claramente más allá del mínimo. La solución está explícitamente diseñada para ser reutilizada con datos reales de CENTINELA+ (mismos esquemas de datos, mismas variables, instrucciones de transición). Se proponen mejoras concretas y alcanzables para la siguiente fase del proyecto. El equipo ha investigado de forma autónoma tecnologías no vistas en clase y las ha documentado.
Notable (7-8,9)	El equipo muestra iniciativa en al menos un aspecto del proyecto. Se identifican extensiones posibles aunque no estén totalmente desarrolladas.
Aprobado (5-6,9)	El equipo completa el mínimo requerido. Hay alguna mención a la escalabilidad o extensión futura.
Insuficiente (<5)	El equipo no va más allá de lo estrictamente obligatorio. No se identifica cómo escalar o extender la solución.

Criterio 6 — Calidad del código (5%)

Nivel	Descriptor
Excelente (9-10)	El código sigue PEP8 de forma consistente (verificado con flake8 o black). El repositorio tiene estructura de carpetas clara y coherente. El README está completo (descripción, instalación, uso). El historial de commits es descriptivo y atómico. El .gitignore es correcto (datos y modelos grandes excluidos).
Notable (7-8,9)	El código es legible y está razonablemente organizado. El repositorio tiene README y estructura reconocible. Los commits son suficientemente descriptivos.
Aprobado (5-6,9)	El código funciona aunque puede estar poco organizado o documentado. El repositorio existe con estructura básica y README mínimo.
Insuficiente (<5)	El código es difícilmente legible o no está organizado. No existe repositorio Git o el historial de commits está vacío/sin mensajes.

8.4 Evaluación individual

Aunque la nota principal es por equipo, los profesores podrán, **si lo consideran necesario**, realizar una breve ronda de preguntas a los integrantes del equipo durante la presentación del 29 de mayo para verificar la comprensión global de la solución. Esta ronda no es obligatoria y queda a criterio del profesorado.

En caso de realizarse, cada alumno debe poder defender los siguientes aspectos mínimos:

1. El caso de uso del que fue responsable principal.
2. En qué consiste el benchmark Spark vs. pandas y cuáles fueron los resultados del proyecto.
3. La arquitectura RAG del chatbot de forma básica: qué es RAG, qué papel juega ElasticSearch, qué hace el LLM.