

ANEXO II — RECURSOS DISPONIBLES

Proyecto Integral: Edificios Inteligentes y Sostenibilidad Energética · Curso 2025-2026

5. Recursos disponibles

5.1 Infraestructura tecnológica

Stack tecnológico del proyecto

Capa	Herramientas	Función
Simulación IoT / Ingesta	Mosquitto, Telegraf, Node-RED	Simular flujo de sensores CENTINELA+
Almacenamiento series temporales	InfluxDB v2.x	Base de datos de sensores IoT
Visualización	Grafana	Dashboards en tiempo real
Big Data — almacenamiento	Hadoop HDFS	Almacenamiento distribuido BDG2
Big Data — procesamiento	Apache Spark (PySpark)	Operaciones sobre datasets de varios GB
Big Data — streaming (opc.)	Apache Kafka	Procesamiento de eventos en tiempo real
Base de datos vectorial	ElasticSearch	Búsqueda semántica para RAG
Análisis y ML	Python: pandas, scikit-learn, PyTorch / TensorFlow, statsmodels	Modelos ML/DL
Entornos reproducibles	JupyterHub	Notebooks multiusuario
MLOps — experimentos	MLflow	Trazabilidad de modelos
MLOps — datos	lakeFS	Versionado de datasets
MLOps — competencias (opc.)	Codabench	Evaluación automática de modelos
IA generativa / LLM local	Ollama + LLaMA 3 / Mistral / Qwen / Gemma 4	Chatbot
RAG y agentes	LangChain / LlamaIndex + ElasticSearch	Sistema RAG
Interfaz de usuario	Streamlit / Gradio / React / Flutter / Angular	Demo
Edge computing (opc.)	NVIDIA Jetson Orin Nano	Inferencia en el borde

Capa	Herramientas	Función
Control de versiones	Git (GitHub / GitLab del ITI)	Código fuente

Nota sobre frameworks de interfaz de usuario

Para la interfaz del chatbot y los dashboards de los modelos, los equipos pueden usar:

- **Streamlit** (Python) — Más sencillo, ideal para prototipos rápidos. Crea UIs web con código Python. Recomendado para MVP.
- **Gradio** (Python) — Similar a Streamlit, con componentes prediseñados para IA (chat, imagen, audio).
- **React** (JavaScript) — Framework frontend para aplicaciones web interactivas. Mayor esfuerzo de desarrollo, pero resultado más profesional. Adecuado para equipos con experiencia en desarrollo web.
- **Flutter** (Dart) — Framework de Google para aplicaciones web y móvil multiplataforma desde un único código.
- **Angular** (TypeScript) — Framework frontend empresarial de Google, adecuado para equipos con experiencia en TypeScript.

Recomendación para el MVP: Usar Streamlit o Gradio por su rapidez de desarrollo en Python. React, Flutter o Angular se recomiendan para equipos con experiencia en desarrollo frontend que quieran un resultado más cercano a una aplicación profesional.

Servidores del proyecto (administrados por el equipo ITI)

Clúster Big Data (2-3 nodos):

- **Propósito:** Demostrar empíricamente las ventajas del procesamiento distribuido (Caso I).
- **Servicios desplegados:** Hadoop HDFS, YARN/Spark.
- **Configuración mínima por nodo:** 16 GB RAM, 4 cores, 500 GB disco.
- **El runbook de configuración de este clúster es un entregable formal del proyecto.**

Servidor IA / LLM (1 nodo con GPU):

- **Propósito:** Albergar el LLM local para el chatbot y el sistema de agentes.
- **GPU mínima recomendada:** 16 GB VRAM (para modelos de 7B-13B parámetros en fp16).
- **Servicios desplegados:** Ollama, ElasticSearch, API del sistema RAG y agentes.

Servicios compartidos:

- InfluxDB, Grafana, Node-RED, MLflow, JupyterHub, lakeFS. De forma opcional pueden incorporarse a alguno de los dos servidores anteriores o disponer de un nodo adicional específico para ellos, según los recursos disponibles en el ITI.

5.2 Fuentes de datos — Datasets de edificios inteligentes

Dataset	Tamaño	Resolución	URL / Acceso
BDG2	1.67 GB	Horaria	https://github.com/buds-lab/building-data-genome-project-2
LBNL Building 59	0.56 GB	Variable	https://datadryad.org/stash/dataset/doi:10.7941/D1N33Q
HouseZero	0.05 GB	Minuto	https://figshare.com/articles/dataset/HouseZero_Dataset
LBNL FDD	6.80 GB	Minuto	https://faultdetection.lbl.gov/

BDG2 — Building Data Genome 2 (prioritario para Big Data y predicción de consumo)

- **URL:** <https://github.com/buds-lab/building-data-genome-project-2>
- **Propósito:** Benchmark de predicción de consumo energético en edificios a escala. Es el dataset que justifica el uso de Spark (Caso J).
- **Contenido:**
 - 3.053 contadores de 1.636 edificios reales distribuidos por 19 ubicaciones geográficas (campus universitarios, edificios comerciales y residenciales en EEUU, Europa y Asia).
 - Series temporales horarias de consumo: electricidad, agua caliente, vapor, gas natural, climatización y agua.
 - Metadatos de los edificios: tipo de uso, superficie en m², año de construcción, tipo de sistema HVAC, zona climática.
 - Datos meteorológicos sincronizados (temperatura exterior, punto de rocío, presión, viento, precipitación, cobertura nubosa) para cada ubicación.
 - Más de **53 millones de registros** en total — esto justifica el uso de Spark (Caso de uso I).
- **Ficheros clave:**
 - data/meters/cleaned/electricity.csv — Consumo eléctrico limpio (wide format: columnas = edificios, filas = timestamps).
 - data/metadata/metadata.csv — Metadatos de cada edificio.
 - data/weather/weather.csv — Variables meteorológicas (long format: site_id + timestamp + variables).
- **Desafíos de calidad reales:** hasta el 30% de valores nulos en algunos contadores; cambios de hora estacional (DST); frecuencias de muestreo inconsistentes entre sitios; outliers de consumo cero durante períodos de vacaciones.
- **Licencia:** Creative Commons Attribution 4.0 International (CC BY 4.0).

LBNL Building 59 (Berkeley) — edificio real con IAQ y HVAC completo

- **URL:** <https://datadryad.org/stash/dataset/doi:10.7941/D1N33Q>

- **Propósito:** Análisis detallado de un edificio real con el perfil más completo de variables de confort e IAQ, próximo a lo que medirá CENTINELA+.
- **Contenido:** Datos limpios y crudos 2018-2021.
- **Familias de variables:** electricidad por zona/sistema, HVAC (velocidades de ventiladores, presiones de plenum, caudales, temperaturas de suministro y retorno, válvulas, dampers, setpoints) e IAQ (CO₂, PM1.0/2.5/10, TVOC, humedad, temperatura, presión, lux, dB). Tamaño: 0.56 GB.
- **Fichero IAQ clave:** IAQ.csv — columnas: co2, pm1.0, pm2.5, pm10, tvoc, humidity, temperature, pressure, lux, dB.average. Incluye modelo semántico Brick del edificio (Bldg59.ttl).

HouseZero — dataset pequeño para inicio rápido

- **URL:** https://figshare.com/articles/dataset/HouseZero_Dataset
- **Contenido:** Casa experimental de Harvard.
- Variables interiores (CO₂, temperatura, humedad por zona), exterior (clima), sistema geotérmico, TABS, apertura de ventanas, válvulas y cargas eléctricas.
- Dataset pequeño (~0.05 GB), limpio y bien estructurado. Ideal para validar pipelines antes de escalar a BDG2.

LBNL FDD — detección de fallos en HVAC

- **URL:** <https://faultdetection.lbl.gov/>
- **DOI:** <https://dx.doi.org/10.25984/188132>
- **Propósito:** Benchmark de detección y diagnóstico de fallos en sistemas HVAC.
- **Contenido:** Series temporales de múltiples subsistemas HVAC en condiciones normales y con fallos etiquetados (simulados con alta fidelidad física):
 - **SDAHU** (*Single Duct Air Handling Unit*): UTA de conducto único. Variables: temperaturas de aire (exterior, mezclado, suministro, retorno), caudales, presiones, velocidad de ventiladores, válvulas de agua fría/caliente, dampers. Fallos: sesgo de sensor de temperatura, fuga de damper de aire exterior, fallo del economizador.
 - **DDAHU** (*Dual Duct Air Handling Unit*): UTA de doble conducto. Variables similares al SDAHU pero con dos deck (caliente y frío). Fallos: atasco de válvula de bobina, sesgo de sensor.
 - **FCU** (*Fan Coil Unit*): Fancoil. Variables: temperatura de agua de suministro/retorno, posición de válvula, velocidad de ventilador, temperatura de zona. Fallos: válvula atascada, ventilador degradado.
 - **FPU** (*Fan-Powered Unit*): Unidad de caudal variable con ventilador. Similar al FCU.
 - **Boiler Plant** (Planta de calderas): Variables de temperatura de agua caliente, caudal, estado de quemadores, eficiencia. Fallos: sesgo de sensor de temperatura, exceso de purga.
 - **Chiller Plant** (Planta de chillers): Variables de temperatura de agua fría, caudal, potencia del compresor, COP. Fallos: incrustaciones en condensador, refrigerante bajo.
 - **RTU** (*Rooftop Unit*): Unidad de techo. Variables: temperaturas de zona, suministro y retorno, velocidad de ventiladores, consumo eléctrico total del HVAC, modo de ocupación (OCCU_MOD). Más de 35 puntos de medida por instancia.
- **Tamaño local:** 6.80 GB (21 archivos ZIP) — El mayor de los datasets disponibles.

- **Estructura:** Cada ZIP contiene CSVs con las series temporales. La columna Datetime es el índice temporal.

Recomendación de inicio: Empezar con el subsistema **RTU** o **FCU** por su tamaño manejable y la claridad de las etiquetas de fallo. El subsistema Boiler o Chiller es más complejo y adecuado para grupos avanzados.

5.3 Fuentes de datos — Datasets de aulas (próximos a CENTINELA+)

Dataset	Tamaño	Resolución	URL / Acceso
In-Gauge / En-Gage	~100 MB	Minuto	https://physionet.org/content/in-gauge-and-en-gage/1.0.0/
UCI Appliances Energy	~3 MB	10 minutos	https://archive.ics.uci.edu/dataset/374
UCI Occupancy Detection	~2 MB	Minuto	https://archive.ics.uci.edu/dataset/357

In-Gauge / En-Gage — Classrooms IAQ and Noise (muy recomendado)

- **URL:** <https://physionet.org/content/in-gauge-and-en-gage/1.0.0/>
- **DOI:** <https://doi.org/10.13026/qb96-5v06>
- **Publicación asociada:** Gao et al. (2022). *Classrooms' indoor air quality and acoustic environment assessment using wearable sensors*. Scientific Data, 9, 238. <https://doi.org/10.1038/s41597-022-01347-w>
- **Propósito:** Dataset de calidad del aire interior y ambiente acústico en aulas educativas reales. Es el **dataset más alineado con CENTINELA+** de todos los disponibles, porque procede exactamente del mismo tipo de entorno (aulas escolares) con las mismas variables.
- **Contenido:** 16 ficheros CSV (uno por aula), cada uno con resolución de 1 minuto durante varios días de actividad escolar:

Variable	Descripción	Unidad
Indoor_Temp	Temperatura interior	°C
Indoor_Hum	Humedad relativa interior	%
Indoor_CO2	CO ₂ interior	ppm
Indoor_Noise	Ruido interior	dB
Outdoor_Temp/Hum/Dew/Wind/Precip/UV/Solar	Variables exteriores completas	Varias
Occupied / SchoolDay / LessonNumber / LessonPct	Indicadores de ocupación y horario lectivo	0/1 / entero / %
CoolingState / HeatingState	Estado del sistema HVAC	0/1
UsabilityMask	Indicador de calidad del dato	0/1

- **Licencia:** Open Data Commons Attribution License v1.0 (ODC-By 1.0).

UCI Appliances Energy Prediction

- **URL:** <https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction>
- **Propósito:** Predicción del consumo de electrodomésticos e iluminación con variables interiores y exteriores.
- **Contenido:** Serie temporal a resolución de **10 minutos** de una casa en Bélgica (137 días, ~20.000 registros).
- **Variables:** consumo de electrodomésticos (Appliances, Wh), consumo de iluminación (lights, Wh), temperaturas interiores por estancia (T1–T9, °C), humedades relativas interiores (RH_1–RH_9, %), y meteorología exterior: temperatura (T_out), humedad (RH_out), presión (Press_mm_hg), velocidad del viento (Windspeed), visibilidad (Visibility) y punto de rocío (Tdewpoint).
- **Dimensiones:** 19.735 observaciones × 29 variables.
- **Licencia:** Creative Commons Attribution 4.0 International (CC BY 4.0).
- **Referencia:** Candanedo et al. (2017). *Energy and Buildings*, vol. 140.

UCI Occupancy Detection

- **URL:** <https://archive.ics.uci.edu/dataset/357/occupancy+detection>
- **Propósito:** Clasificación supervisada de ocupación de oficina a partir de variables ambientales.
- **Publicación:** Candanedo & Feldheim (2016). *Accurate occupancy detection of an office room from light, temperature, humidity and CO2 measurements using statistical learning models*. *Energy and Buildings*, 112, 28–39.
- **Contenido:** Mediciones cada minuto en una oficina en Bélgica durante varios días, con etiqueta binaria de ocupación verificada por cámara.
 - date — Timestamp (minuto a minuto).
 - Temperature — Temperatura interior (°C).
 - Humidity — Humedad relativa (%).
 - Light — Luminosidad (lux).
 - CO2 — Concentración de CO₂ (ppm).
 - HumidityRatio — Ratio de humedad (cantidad de agua en aire / cantidad de aire seco).
 - Occupancy — Etiqueta: 1 (ocupado) / 0 (desocupado).
- **Particiones:** datatraining.txt (8.143 registros), datatest.txt (2.665 registros), datatest2.txt (9.752 registros).
- **Nota pedagógica:** El dataset es pequeño y limpio (sin nulos significativos), ideal como punto de entrada antes de escalar a In-Gauge/En-Gage.
- **Licencia:** Dominio público / CC0.

5.4 Fuentes de datos — Datasets meteorológicos

Dataset	Tamaño	Resolución	URL / Acceso
ERA5	ECMWF / Copernicus	0.25° (~28 km)	https://cds.climate.copernicus.eu/
SARAH-3 (opcional)	CM SAF / EUMETSAT	0.05° (~5.5 km)	https://wui.cmsaf.eu/

ERA5 — ECMWF Reanalysis v5 (dataset meteorológico principal)

- **Organización:** ECMWF (European Centre for Medium-Range Weather Forecasts).
- **URL de acceso:** <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels>
- **Propósito:** Reanálisis climático global de alta resolución que cubre desde 1940 hasta el presente. Combina modelos numéricos de predicción del tiempo con observaciones históricas para generar un conjunto de datos climáticos globales consistente y homogéneo. **Base para modelos de predicción de consumo y propuesta AVAMET.**
- **URLs de descarga directa:**
<https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels?tab=download>
 - **Reanálisis Climático Global:**
Es importante que crees una cuenta gratuita en el portal de Copernicus para acceder y gestionar tus solicitudes de descarga.
Tamaño Estimado: Para el caso práctico descrito en el documento (Península Ibérica, 10 años, 2 variables), un archivo NetCDF suele ocupar unos **6 GB**. La CDS te permite seleccionar un área de interés para reducir el volumen de datos. Como referencia, un archivo con la información de un solo año y una sola variable para toda Europa puede rondar los 1.5 GB.
 - **Radiación Solar:**
Al igual que el dataset principal, se descarga desde el mismo catálogo del CDS. Solo deberás marcar la variable `surface_solar_radiation_downwards` al hacer tu solicitud.
Tamaño Estimado: Incluir esta variable (radiación solar) en tu solicitud aumentará el tamaño del archivo final. Si descargas las mismas dos variables base (temperatura y precipitación) y le añades esta, el archivo de 6GB pasará a ocupar aproximadamente **9 GB**.
 - **Viento:**
Podrás seleccionar las componentes 10m u-component of wind y 10m v-component of wind.
Tamaño Estimado: Si descargas las dos componentes del viento (U y V) junto con las variables climáticas base, el archivo podría alcanzar aproximadamente **9 GB**, un tamaño similar al del caso de la radiación solar.
- **Variables disponibles** (selección relevante para el proyecto):

Variable ERA5	Descripción	Conversión de unidades
2m_temperature	Temperatura del aire a 2 m	$K - 273.15 = ^\circ C$
surface_solar_radiation_downwards	Radiación solar entrante en superficie	J/m^2 , acumulada horaria → dividir por 3600 para W/m^2
total_precipitation	Precipitación acumulada horaria	$m \times 1000 = mm$
10m_u_component_of_wind y 10m_v_component_of_wind	Componentes u/v del viento a 10 m	$\sqrt{u^2+v^2}$ = velocidad m/s
2m_dewpoint_temperature	Punto de rocío a 2 m	$K - 273.15 = ^\circ C$
surface_pressure	Presión en superficie	$Pa \div 100 = hPa$
relative_humidity	Humedad relativa	%

- **Resolución espacial:** $0.25^\circ \times 0.25^\circ$ (~28 km en latitudes medias). Para Xàtiva: celda de rejilla en aprox. $39^\circ N$, $0.5^\circ W$.
- **Resolución temporal:** Horaria (desde 1940 al presente).
- **Licencia:** Copernicus Licence — uso libre para investigación y educación, con atribución.
- **Herramienta de descarga:** cdsapi (Python). Instalación: `pip install cdsapi`. Requiere registro gratuito en <https://cds.climate.copernicus.eu> y configuración de la API key en `~/cdsapirc`.

SARAH-3 — Radiación solar satelital (opcional, mayor precisión)

- **Organización:** CM SAF (Climate Monitoring Satellite Application Facility) — EUMETSAT.
- **URL:** <https://wui.cmsaf.eu/safira/action/viewProduktSearch>
- **DOI:** https://doi.org/10.5676/EUM_SAF_CM/SARAH/V003
- **Propósito:** Dataset de radiación solar en superficie derivado de imágenes del satélite Meteosat, con **mayor precisión y resolución espacial** que ERA5 para la componente de radiación solar. Especialmente recomendado cuando la energía solar fotovoltaica es el objetivo principal del análisis.
- **Variables disponibles:**
 - SIS (*Surface Incoming Shortwave radiation*) — Radiación solar global en superficie (W/m^2). Equivalente al GHI.
 - DNI (*Direct Normal Irradiance*) — Irradiancia directa normal (W/m^2).
 - CAL — Cobertura nubosa efectiva.
 - SDU — Horas de sol.
- **Resolución espacial:** $0.05^\circ \times 0.05^\circ$ (~5.5 km) — significativamente mayor que ERA5.
- **Resolución temporal:** Horaria o diaria.
- **Cobertura geográfica:** Europa, África y Oriente Medio (cubiertos por Meteosat).
- **Período:** 1983–presente.
- **Licencia:** Uso gratuito para investigación y educación, con registro y atribución.

- **Nota de uso:** SARA3 se recomienda específicamente para el modelo de predicción de generación fotovoltaica. Para el resto de variables meteorológicas, ERA5 es suficiente y más sencillo de usar.

5.5 Fuentes de datos — Datasets complementarios Big Data/ML

Dataset	Propósito principal	URL
Favorita	Forecasting de series temporales a gran escala	https://www.kaggle.com/c/favorita-grocery-sales-forecasting
PaySim	Detección de anomalías en transacciones (fraude)	https://www.kaggle.com/datasets/ealaxi/paysim1
Instacart	Segmentación y clustering de clientes	https://www.instacart.com/datasets/grocery-shopping-2017